机器学习作业一

- 姓名：周延霖
- 学号：2013921
- 专业：信息安全

实验要求

题目：基于KNN 的手写数字识别 实验条件：给定semeion手写数字数据集，给定kNN分类算法 实验要求：

1. 基本要求：编程实现kNN算法；给出在不同k值（1，3，5）情况下，kNN算法对手写数字的识别精度（要求采用留一法）
2. 中级要求：与weka机器学习包中的kNN分类结果进行对比
3. 提高要求：将实验过程结果等图示展出

截止日期：10月7日

- 以.ipynb形式的文件提交，输出运行结果，并确保自己的代码能够正确运行
- 发送到邮箱：2120220594@mail.nankai.edu.cn

导入需要的包

In [1]:
```
import numpy as np
import operator
from collections import Counter
from sklearn.model_selection import train_test_split,cross_val_score
from sklearn.model_selection import LeaveOneOut
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import KFold
# 为新导入的实现留一法的包，其实最后并没有用到
from tqdm import tqdm
import matplotlib.pyplot as plt
import time
```

导入数据集 semesion

In [2]:
```
# 导入数据
def Img2Mat(fileName):
    f = open(fileName)
    ss = f.readlines()
    l = len(ss)
    f.close()
    returnMat = np.zeros((l,256))
    returnClassVector = np.zeros((l,1))
    for i in range(l):
        s1 = ss[i].split()
        for j in range(256):
            returnMat[i][j] = np.float(s1[j])
        clCount = 0
        for j in range(256,266):
            if s1[j] != '1':
```

```
                clCount += 1
            else:
                break
        returnClassVector[i] = clCount
    return returnMat,returnClassVector
```

In [3]:
```
X,y = Img2Mat('semeion.data')
np.shape(X), np.shape(y)
```

```
/var/folders/3g/0qh1978d1klcf1y3cxll683r0000gn/T/ipykernel_81871/2757158993.
py:12: DeprecationWarning: `np.float` is a deprecated alias for the builtin
`float`. To silence this warning, use `float` by itself. Doing this will not
modify any behavior and is safe. If you specifically wanted the numpy scalar
type, use `np.float64` here.
Deprecated in NumPy 1.20; for more details and guidance: https://numpy.org/d
evdocs/release/1.20.0-notes.html#deprecations
  returnMat[i][j] = np.float(s1[j])
```

Out[3]:
```
((1593, 256), (1593, 1))
```

基本要求

编程实现kNN算法；给出不同k值（1，3，5）情况下，kNN算法对手写数字的识别精度（模板中采用的是普通方法分割训练集和测试集，作业中需要用留一法）

In [4]:
```
# # KNN算法手动实现
# def MyKnnClassifier(data_X, data_y, neighbors):
#     # 生成数据集和测试集
#     X_train, X_test, y_train, y_test = train_test_split(data_X, data_y, te
#     trainShape = X_train.shape[0]   # 获得训练集的大小
#     testShape = X_test.shape[0]     # 获得测试集的大小
#     testRes = []  # 存放测试结果
#     acc = 0   # 计算准确率
#     for i in range(testShape):  # 针对测试集中每一个样本进行预测
#         # 差异矩阵 = 该样本与训练集中所有样本之差构成的矩阵
#         testDiffMat = np.tile(X_test[i],(trainShape , 1)) - X_train
#         sqTestDiffMat = testDiffMat ** 2    # 将差异矩阵平方
#         # 方差距离为方差矩阵的整行求和，是一个一位列向量
#         sqTestDiffDis = sqTestDiffMat.sum(axis=1)
#         testDiffDis = sqTestDiffDis ** 0.5  # 开方生成标准差距离
#         sortIndex = np.argsort(testDiffDis)   # 将标准差距离按照下标排序
#         labelCount = []
#         for j in range(neighbors):  # 考察k近邻属于哪些类
#             labelCount.append(y_train[sortIndex[j]][0])
#         classifyRes = Counter(labelCount)    # 把k近邻中最多的那个标签作为分类结
#         classifyRes = classifyRes.most_common(2)[0][0]
#         testRes.append(classifyRes)
#         if classifyRes == y_test[i]:  # 分类正确则将accRate+1
#             acc += 1
#     accRate = acc / X_test.shape[0]
#     print('k={0}时，测试个数为{1}  正确个数为：{2}  准确率为：{3}'.format(neighb
#     return accRate
# 以上老师为所写的普通方法

# KNN算法采用留一法实现
def MyKnnClassifier(data_X, data_y, neighbors):
    # kf = KFold(n_splits = 1)
    # 总共进行data_X.shape[0]次
    # 总正确个数
    acc_sum = 0
    # 总正确率
    # accRate_sum = 0
```

```
    # for train_index, test_index in kf.split(data_X):
    for test_index in range(data_X.shape[0]):
        # 下面生成训练集的下标
        train_index = []
        for i in range(data_X.shape[0]):
            if i == test_index:
                continue
            else:
                train_index.append(i)
        # 生成数据集和测试集
        X_train = data_X[train_index]
        X_test = []
        X_test.append(data_X[test_index])
        # np.shape(X_test)
        y_train = data_y[train_index]
        y_test = []
        y_test.append(data_y[test_index])
        # np.shape(y_test)
        # 获得训练集的大小
        trainShape = X_train.shape[0]
        # 获得测试集的大小
        # testShape = X_test.shape[0]
        testShape = 1
        # print(testShape)
        # print(trainShape)
        testRes = []  # 存放测试结果
        acc = 0   # 计算准确率
        for i in range(testShape):  # 这里testShape = 1, 之所以用循环是因为不想改
            # 差异矩阵 = 该样本与训练集中所有样本之差构成的矩阵
            testDiffMat = np.tile(X_test[i],(trainShape , 1)) - X_train
            sqTestDiffMat = testDiffMat ** 2    # 将差异矩阵平方
            # 方差距离为方差矩阵的整行求和，是一个一位列向量
            sqTestDiffDis = sqTestDiffMat.sum(axis=1)
            testDiffDis = sqTestDiffDis ** 0.5  # 开方生成标准差距离
            sortIndex = np.argsort(testDiffDis)   # 将标准差距离按照下标排序
            labelCount = []
            for j in range(neighbors):  # 考察k近邻属于哪些类
                labelCount.append(y_train[sortIndex[j]][0])
            classifyRes = Counter(labelCount)    # 把k近邻中最多的那个标签作为分
            classifyRes = classifyRes.most_common(2)[0][0]
            testRes.append(classifyRes)
            if classifyRes == y_test[i]:  # 分类正确则将accRate+1
                acc += 1

        acc_sum = acc_sum + acc
        # accRateTemplate = acc / X_test.shape[0]
        # accRate_sum = accRate_sum + accRateTemplate

    acc = acc_sum
    accRate = acc_sum / data_X.shape[0]
    print('k={0}时，测试个数为{1}  平均正确个数为：{2}  平均准确率为：{3}'.format(n
    return accRate
```

实验结果：

In [5]:
```
MyKnnClassifier(X, y, 1)
MyKnnClassifier(X, y, 3)
MyKnnClassifier(X, y, 5)
```

```
k=1时，测试个数为1593  平均正确个数为：1459  平均准确率为：0.9158819836785939
k=3时，测试个数为1593  平均正确个数为：1464  平均准确率为：0.9190207156308852
k=5时，测试个数为1593  平均正确个数为：1458  平均准确率为：0.9152542372881356
```

Out[5]:
```
0.9152542372881356
```

中级要求

模板中与sklearn机器学习包中的kNN分类结果进行对比（作业中需要与weka机器学习包中的kNN分类结果进行对比）

In [6]:
```
# # kNN算法sklearn库实现
# def KnnClassifier(data_X, data_y, neighbors, flag=0):
#     X_train, X_test, y_train, y_test = train_test_split(data_X, data_y, te
#     knn = KNeighborsClassifier(n_neighbors=neighbors)
#     knn.fit(X_train, y_train.ravel())
#     print('k={0}时，scikit-learn训练手写体识别的准确率为：{1}'.format(neighbors
#     # 交叉验证
#     if flag == 1:
#         scores = cross_val_score(knn,data_X,data_y.ravel(),cv=10,scoring='
#         return scores.mean()
```

由于本人导入weka包的时候频繁报错，所以转换成为直接使用现成的weka工具来进行本次实验，将semeion.data先修改后缀转换成为txt文件，再将txt文件通过如下代码转换成为csv文件：

In [7]:
```
# 将txt转换成csv
import numpy as np
import pandas as pd

data_txt = np.loadtxt('semeion.txt')
data_txtDF = pd.DataFrame(data_txt)
data_txtDF.to_csv('semeion.csv',index=False)
```

接下来对转换成功的csv文件的后10列进行处理，使其形成10个类别，变成semeion(1).csv文件。

最后用weka工具将semeion(1).csv转换成为semeion.arff文件，然后就可以分析了，将文件导入的工具中，初始效果如下图所示：

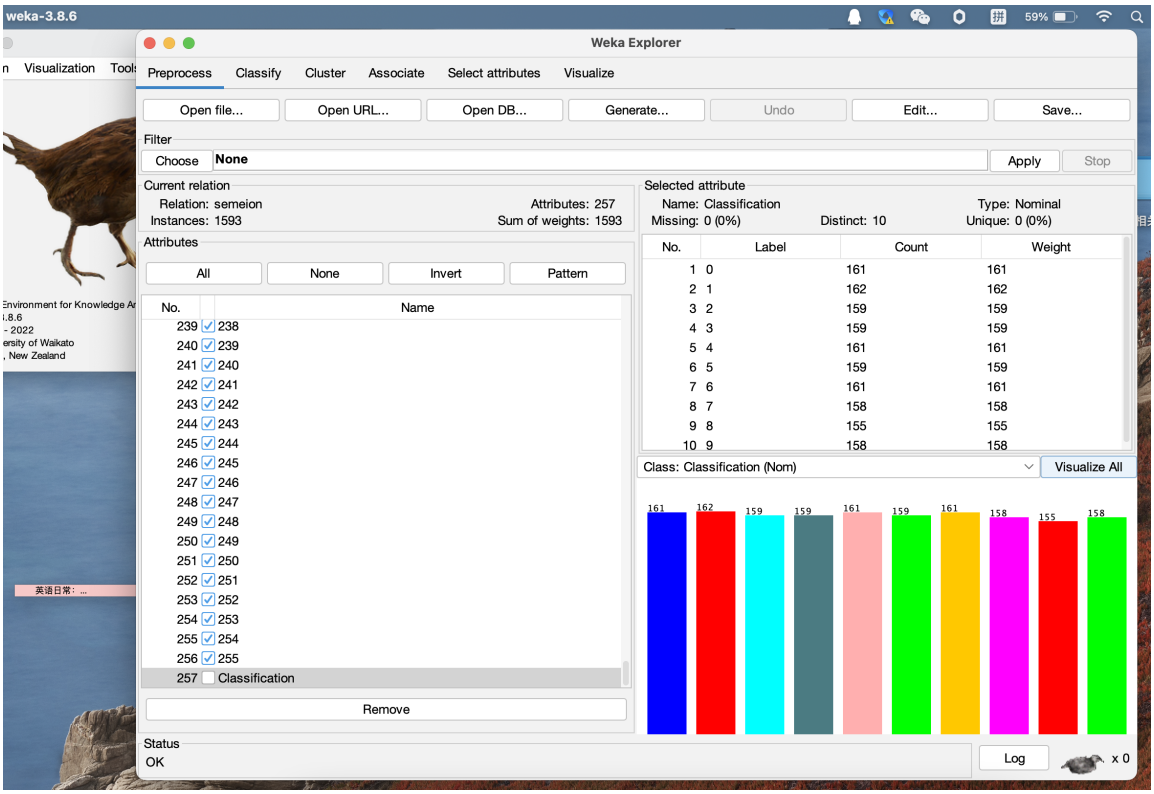

实验结果：

当 k = 1 时运行工具所得到的结果如下图所示：

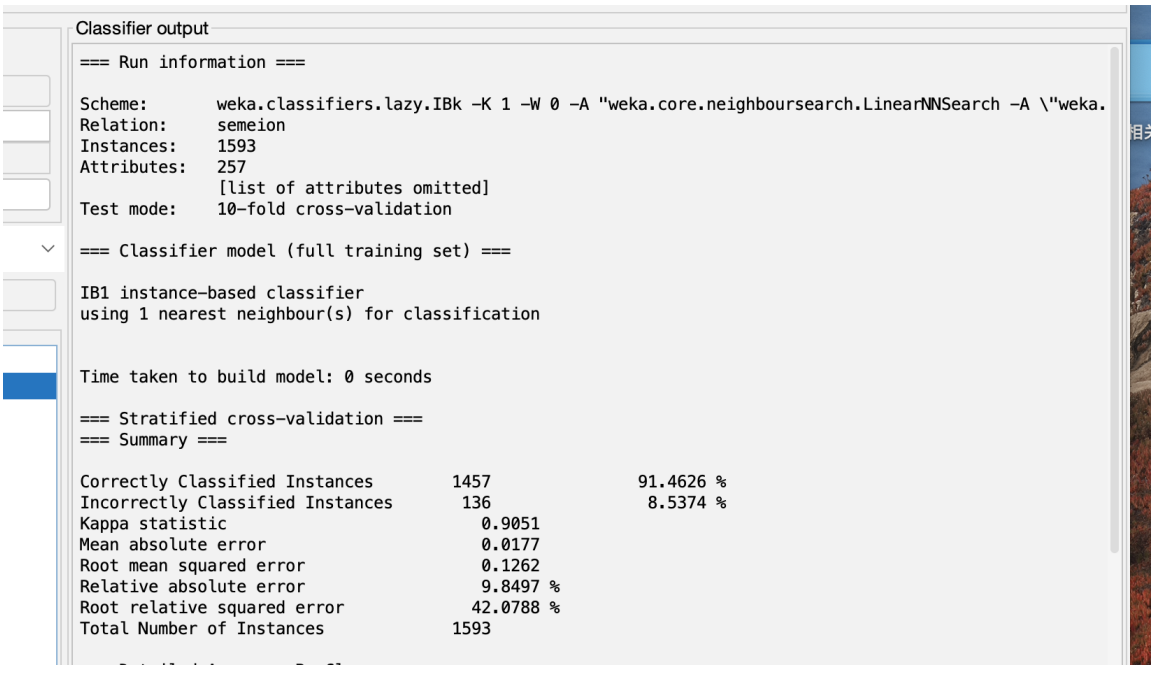

Classifier output

```
=== Run information ===

Scheme:       weka.classifiers.lazy.IBk -K 1 -W 0 -A "weka.core.neighboursearch.LinearNNSearch -A \"weka.
Relation:     semeion
Instances:    1593
Attributes:   257
              [list of attributes omitted]
Test mode:    10-fold cross-validation

=== Classifier model (full training set) ===

IB1 instance-based classifier
using 1 nearest neighbour(s) for classification


Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances        1457               91.4626 %
Incorrectly Classified Instances       136                8.5374 %
Kappa statistic                          0.9051
Mean absolute error                      0.0177
Root mean squared error                  0.1262
Relative absolute error                  9.8497 %
Root relative squared error             42.0788 %
Total Number of Instances             1593
```

按类别划分的详细精度和混淆矩阵如下图所示：

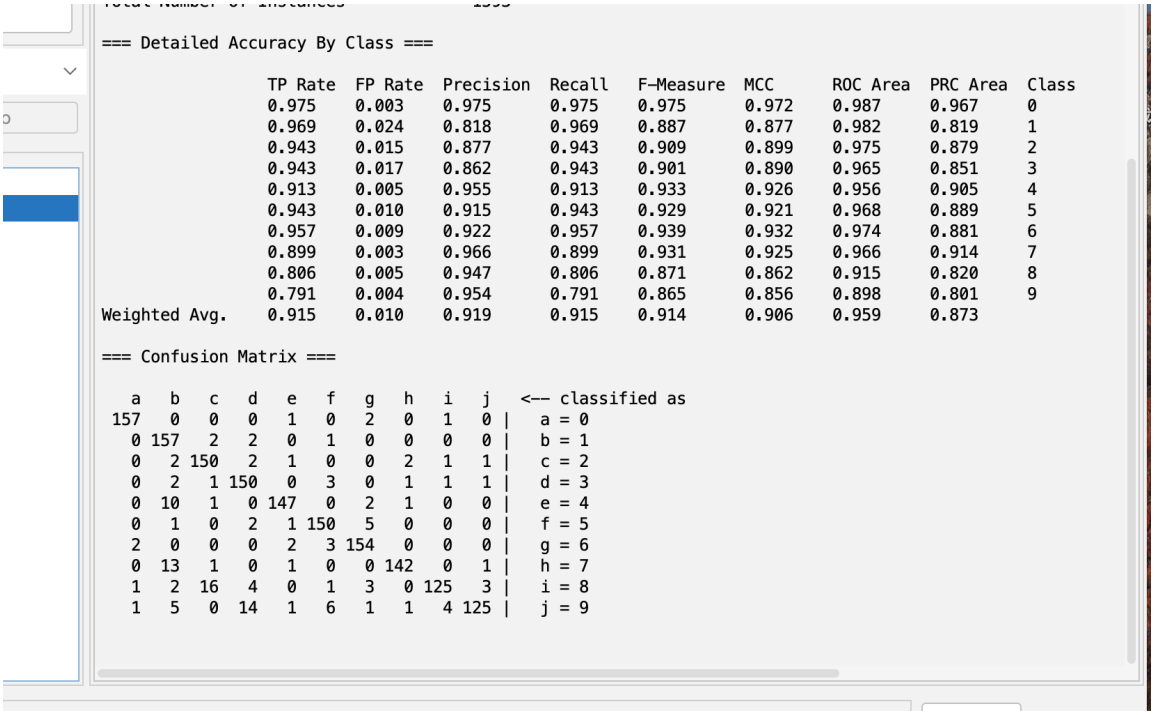

```
=== Detailed Accuracy By Class ===

                 TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                 0.975    0.003    0.975      0.975    0.975      0.972    0.987     0.967     0
                 0.969    0.024    0.818      0.969    0.887      0.877    0.982     0.819     1
                 0.943    0.015    0.877      0.943    0.909      0.899    0.975     0.879     2
                 0.943    0.017    0.862      0.943    0.901      0.890    0.965     0.851     3
                 0.913    0.005    0.955      0.913    0.933      0.926    0.956     0.905     4
                 0.943    0.010    0.915      0.943    0.929      0.921    0.968     0.889     5
                 0.957    0.009    0.922      0.957    0.939      0.932    0.974     0.881     6
                 0.899    0.003    0.966      0.899    0.931      0.925    0.966     0.914     7
                 0.806    0.005    0.947      0.806    0.871      0.862    0.915     0.820     8
                 0.791    0.004    0.954      0.791    0.865      0.856    0.898     0.801     9
Weighted Avg.    0.915    0.010    0.919      0.915    0.914      0.906    0.959     0.873

=== Confusion Matrix ===

   a   b   c   d   e   f   g   h   i   j   <-- classified as
 157   0   0   0   1   0   2   0   1   0 |   a = 0
   0 157   2   2   0   1   0   0   0   0 |   b = 1
   0   2 150   2   1   0   0   2   1   1 |   c = 2
   0   2   1 150   0   3   0   1   1   1 |   d = 3
   0  10   1   0 147   0   2   1   0   0 |   e = 4
   0   1   0   2   1 150   5   0   0   0 |   f = 5
   2   0   0   0   2   3 154   0   0   0 |   g = 6
   0  13   1   0   1   0   0 142   0   1 |   h = 7
   1   2  16   4   0   1   3   0 125   3 |   i = 8
   1   5   0  14   1   6   1   1   4 125 |   j = 9
```

当 k = 3 时运行工具所得到的结果如下图所示：

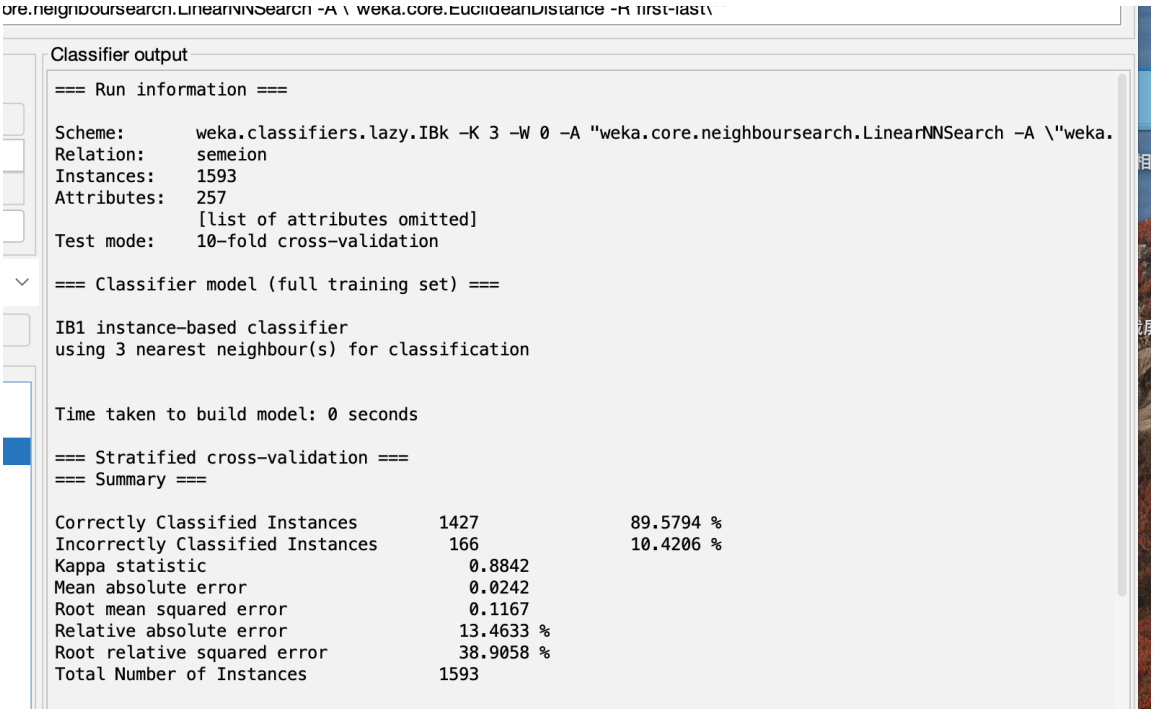

```
Classifier output

=== Run information ===

Scheme:       weka.classifiers.lazy.IBk -K 3 -W 0 -A "weka.core.neighboursearch.LinearNNSearch -A \"weka.
Relation:     semeion
Instances:    1593
Attributes:   257
              [list of attributes omitted]
Test mode:    10-fold cross-validation

=== Classifier model (full training set) ===

IB1 instance-based classifier
using 3 nearest neighbour(s) for classification


Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances        1427               89.5794 %
Incorrectly Classified Instances       166               10.4206 %
Kappa statistic                          0.8842
Mean absolute error                      0.0242
Root mean squared error                  0.1167
Relative absolute error                 13.4633 %
Root relative squared error             38.9058 %
Total Number of Instances             1593
```

按类别划分的详细精度和混淆矩阵如下图所示：

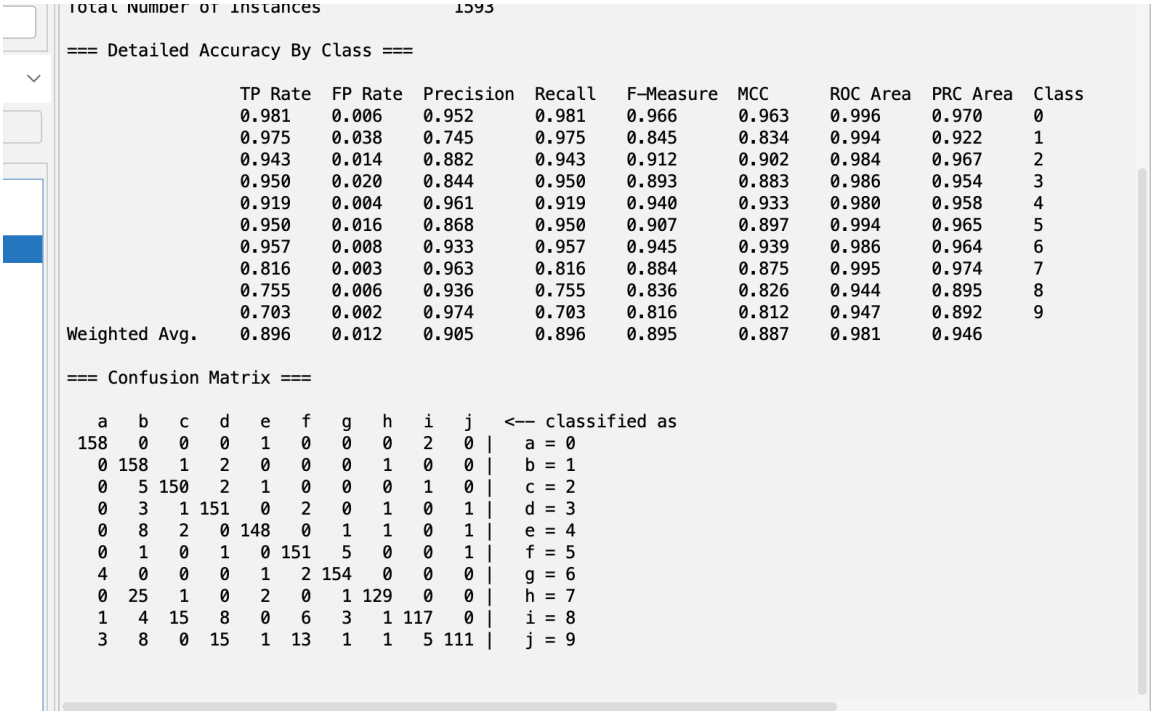

```
Total Number of Instances             1593

=== Detailed Accuracy By Class ===

                 TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                 0.981    0.006    0.952      0.981    0.966      0.963    0.996     0.970     0
                 0.975    0.038    0.745      0.975    0.845      0.834    0.994     0.922     1
                 0.943    0.014    0.882      0.943    0.912      0.902    0.984     0.967     2
                 0.950    0.020    0.844      0.950    0.893      0.883    0.986     0.954     3
                 0.919    0.004    0.961      0.919    0.940      0.933    0.980     0.958     4
                 0.950    0.016    0.868      0.950    0.907      0.897    0.994     0.965     5
                 0.957    0.008    0.933      0.957    0.945      0.939    0.986     0.964     6
                 0.816    0.003    0.963      0.816    0.884      0.875    0.995     0.974     7
                 0.755    0.006    0.936      0.755    0.836      0.826    0.944     0.895     8
                 0.703    0.002    0.974      0.703    0.816      0.812    0.947     0.892     9
Weighted Avg.    0.896    0.012    0.905      0.896    0.895      0.887    0.981     0.946

=== Confusion Matrix ===

   a   b   c   d   e   f   g   h   i   j   <-- classified as
 158   0   0   0   1   0   0   0   2   0 |   a = 0
   0 158   1   2   0   0   0   1   0   0 |   b = 1
   0   5 150   2   1   0   0   0   1   0 |   c = 2
   0   3   1 151   0   2   0   1   0   1 |   d = 3
   0   8   2   0 148   0   1   1   0   1 |   e = 4
   0   1   0   1   0 151   5   0   0   1 |   f = 5
   4   0   0   0   1   2 154   0   0   0 |   g = 6
   0  25   1   0   2   0   1 129   0   0 |   h = 7
   1   4  15   8   0   6   3   1 117   0 |   i = 8
   3   8   0  15   1  13   1   1   5 111 |   j = 9
```

当 k = 5 时运行工具所得到的结果如下图所示：

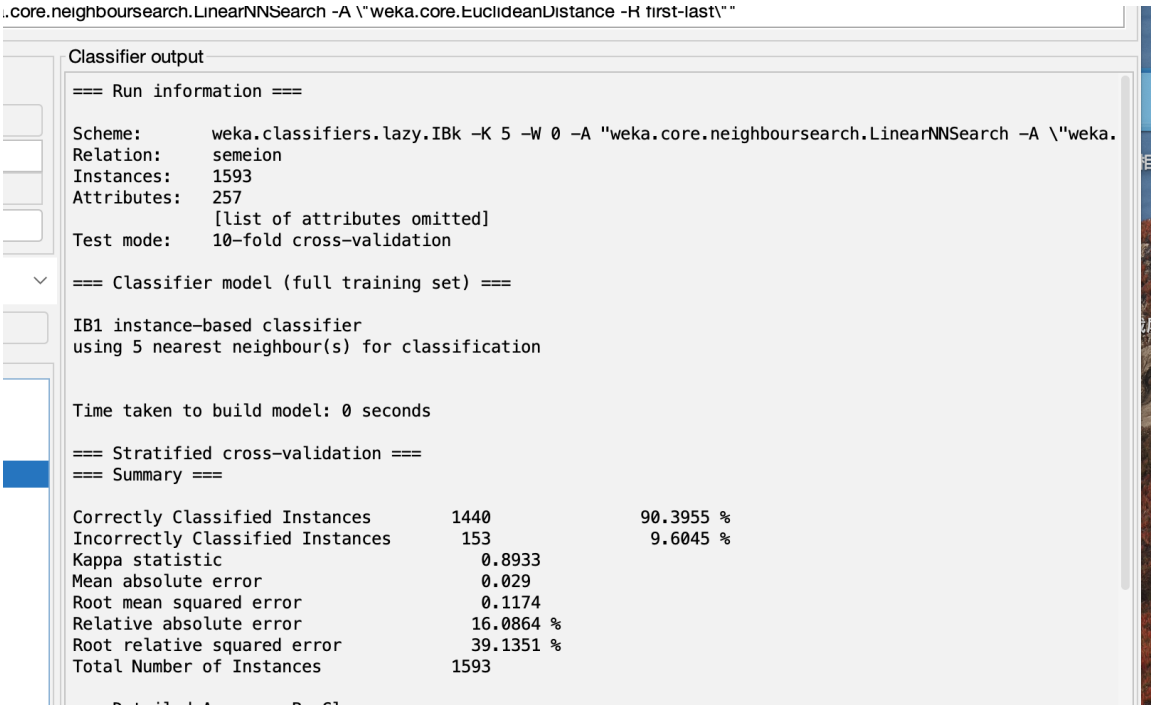

```
.core.neighboursearch.LinearNNSearch -A \"weka.core.EuclideanDistance -R first-last\""

Classifier output

=== Run information ===

Scheme:       weka.classifiers.lazy.IBk -K 5 -W 0 -A "weka.core.neighboursearch.LinearNNSearch -A \"weka.
Relation:     semeion
Instances:    1593
Attributes:   257
              [list of attributes omitted]
Test mode:    10-fold cross-validation

=== Classifier model (full training set) ===

IB1 instance-based classifier
using 5 nearest neighbour(s) for classification


Time taken to build model: 0 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances        1440               90.3955 %
Incorrectly Classified Instances       153                9.6045 %
Kappa statistic                          0.8933
Mean absolute error                      0.029
Root mean squared error                  0.1174
Relative absolute error                 16.0864 %
Root relative squared error             39.1351 %
Total Number of Instances             1593
```

按类别划分的详细精度和混淆矩阵如下图所示：

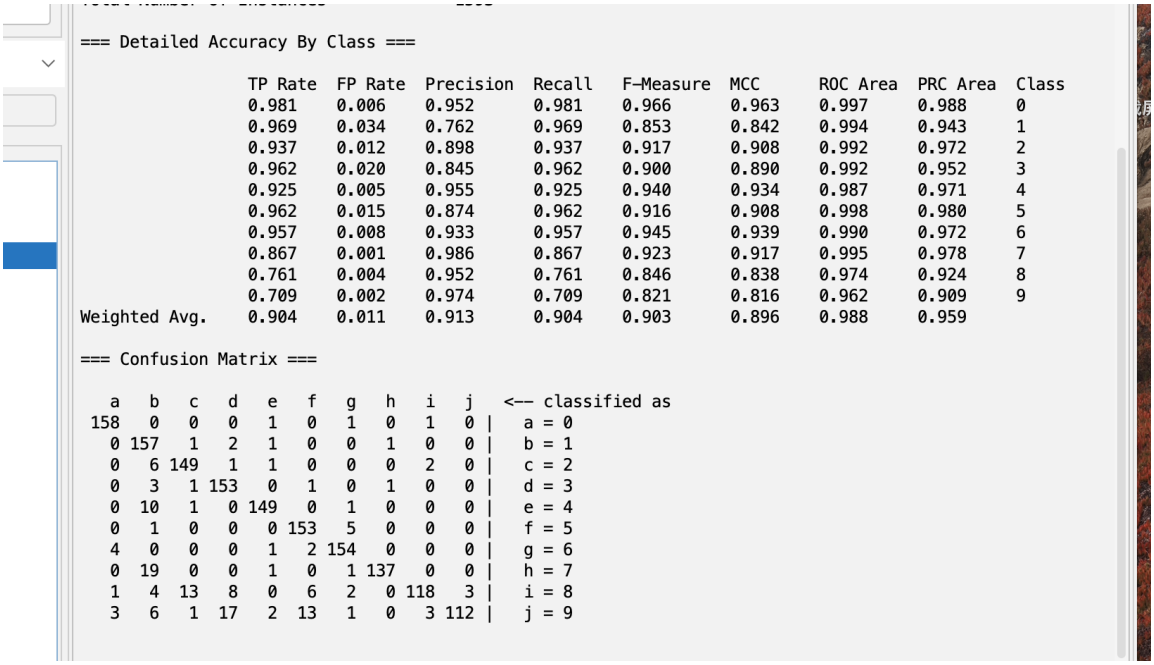

```
=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0.981    0.006    0.952      0.981    0.966      0.963    0.997     0.988     0
               0.969    0.034    0.762      0.969    0.853      0.842    0.994     0.943     1
               0.937    0.012    0.898      0.937    0.917      0.908    0.992     0.972     2
               0.962    0.020    0.845      0.962    0.900      0.890    0.992     0.952     3
               0.925    0.005    0.955      0.925    0.940      0.934    0.987     0.971     4
               0.962    0.015    0.874      0.962    0.916      0.908    0.998     0.980     5
               0.957    0.008    0.933      0.957    0.945      0.939    0.990     0.972     6
               0.867    0.001    0.986      0.867    0.923      0.917    0.995     0.978     7
               0.761    0.004    0.952      0.761    0.846      0.838    0.974     0.924     8
               0.709    0.002    0.974      0.709    0.821      0.816    0.962     0.909     9
Weighted Avg.  0.904    0.011    0.913      0.904    0.903      0.896    0.988     0.959

=== Confusion Matrix ===

   a   b   c   d   e   f   g   h   i   j   <-- classified as
 158   0   0   0   1   0   1   0   1   0 |   a = 0
   0 157   1   2   1   0   0   1   0   0 |   b = 1
   0   6 149   1   1   0   0   0   2   0 |   c = 2
   0   3   1 153   0   1   0   1   0   0 |   d = 3
   0  10   1   0 149   0   1   0   0   0 |   e = 4
   0   1   0   0   0 153   5   0   0   0 |   f = 5
   4   0   0   0   1   2 154   0   0   0 |   g = 6
   0  19   0   0   1   0   1 137   0   0 |   h = 7
   1   4  13   8   0   6   2   0 118   3 |   i = 8
   3   6   1  17   2  13   1   0   3 112 |   j = 9
```

可以看出不论当k为1，3，5时，采用留一法的准确率都要高于weka工具所测得的准确率

高级要求

将实验过程结果等图示展出

In [8]:

```
scores1 = []
# scores2 = []

# 由于weka包的缘故，所以weka的图已经在上文中展示，这里只展示手写的留一法的knn部分

for k in range(1,30):
    score1 = MyKnnClassifier(X, y, k)
    scores1.append(score1)

# for k in range(1,30):
#     score2 = KnnClassifier(X, y, k, 1)
#     scores2.append(score2)
```

```
k=1时，测试个数为1593   平均正确个数为：1459   平均准确率为：0.9158819836785939
k=2时，测试个数为1593   平均正确个数为：1459   平均准确率为：0.9158819836785939
k=3时，测试个数为1593   平均正确个数为：1464   平均准确率为：0.9190207156308852
k=4时，测试个数为1593   平均正确个数为：1465   平均准确率为：0.9196484620213434
k=5时，测试个数为1593   平均正确个数为：1458   平均准确率为：0.9152542372881356
k=6时，测试个数为1593   平均正确个数为：1464   平均准确率为：0.9190207156308852
k=7时，测试个数为1593   平均正确个数为：1469   平均准确率为：0.9221594475831764
k=8时，测试个数为1593   平均正确个数为：1472   平均准确率为：0.9240426867545511
k=9时，测试个数为1593   平均正确个数为：1471   平均准确率为：0.9234149403640929
k=10时，测试个数为1593   平均正确个数为：1465   平均准确率为：0.9196484620213434
k=11时，测试个数为1593   平均正确个数为：1456   平均准确率为：0.9139987445072191
k=12时，测试个数为1593   平均正确个数为：1460   平均准确率为：0.9165097300690521
k=13时，测试个数为1593   平均正确个数为：1461   平均准确率为：0.9171374764595104
k=14时，测试个数为1593   平均正确个数为：1453   平均准确率为：0.9121155053358443
k=15时，测试个数为1593   平均正确个数为：1446   平均准确率为：0.9077212806026366
k=16时，测试个数为1593   平均正确个数为：1446   平均准确率为：0.9077212806026366
k=17时，测试个数为1593   平均正确个数为：1442   平均准确率为：0.9052102950408035
k=18时，测试个数为1593   平均正确个数为：1438   平均准确率为：0.9026993094789705
k=19时，测试个数为1593   平均正确个数为：1436   平均准确率为：0.901443816698054
k=20时，测试个数为1593   平均正确个数为：1435   平均准确率为：0.9008160703075957
k=21时，测试个数为1593   平均正确个数为：1436   平均准确率为：0.901443816698054
k=22时，测试个数为1593   平均正确个数为：1440   平均准确率为：0.903954802259887
k=23时，测试个数为1593   平均正确个数为：1435   平均准确率为：0.9008160703075957
k=24时，测试个数为1593   平均正确个数为：1427   平均准确率为：0.8957940991839297
k=25时，测试个数为1593   平均正确个数为：1426   平均准确率为：0.8951663527934715
k=26时，测试个数为1593   平均正确个数为：1424   平均准确率为：0.8939108600125549
k=27时，测试个数为1593   平均正确个数为：1424   平均准确率为：0.8939108600125549
k=28时，测试个数为1593   平均正确个数为：1417   平均准确率为：0.8895166352793471
k=29时，测试个数为1593   平均正确个数为：1423   平均准确率为：0.8932831136220967
```

将手写体识别的留一法的上述所得到的结果用图片进行展示

In [9]:

```
    plt.xlabel('k value:',fontsize=18)
    plt.ylabel('accuracy',fontsize=18)
    x_major_locator = plt.MultipleLocator(1)
    ax = plt.gca()
    ax.xaxis.set_major_locator(x_major_locator)
    plt.xlim(0, 30)
    plt.ylim(0.75, 1)
    # 普通kNN分类精度
    plt.plot(range(1,30),scores1,'r')
    # 这里只展示手写留一法的knn，原因已在上文中说明
    # plt.plot(range(1,30),scores2,'b')
    plt.show()
```

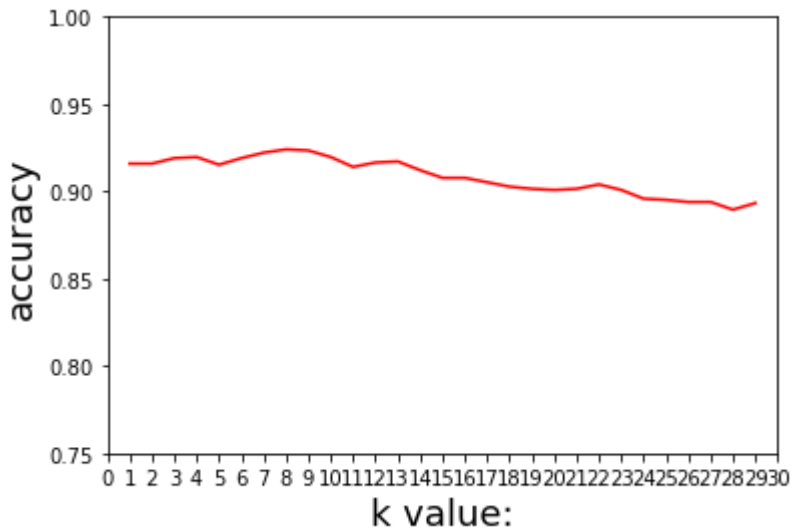

本次实验也到此结束🎉

总结与展望

总结

- 本次是机器学习的第一次实验，在做实验的过程中感受到了一些算法的强大，也通过手写留一法对交叉验证等课堂上所讲述的概念更加的熟悉
- 然后再通过自己对weka工具的探索，虽然最后也没有找到和实现用java代码写，但是对之前上一学年所学习的java课也算有了一定的回顾
- 最后通过使用weka工具成功对knn中k为1，3，5进行了实验，中间在文件格式转换方面也卡了一定的时间，但最后通过助教学长以及同学的帮助也顺利的解决了问题

展望

通过第一次实验，发现自己对机器学习有了更近一步的认识，希望自己能在本学期的课程中学到更多，也希望自己未来能有更好的发展✌